Escuela de Gerencia

# Diplomado en Inteligencia Artificial [Módulo 9: Técnicas Avanzadas de Prompt Engineering]

www.egci.es

Ponente: Guillermo Lescano

Escuela de Gerencia

# Técnicas Avanzadas de Prompt Engineering

- Duración Total: 90 minutos
- Objetivos del Módulo:
  - Técnicas Avanzadas de Prompt Engineering
  - Técnica de Role Playing, limitaciones y JailBreak
  - Generated Knowledge Prompting y Knowledge Integration
  - Técnica de Few-shot Cot y Self-consistency

# Seguridad

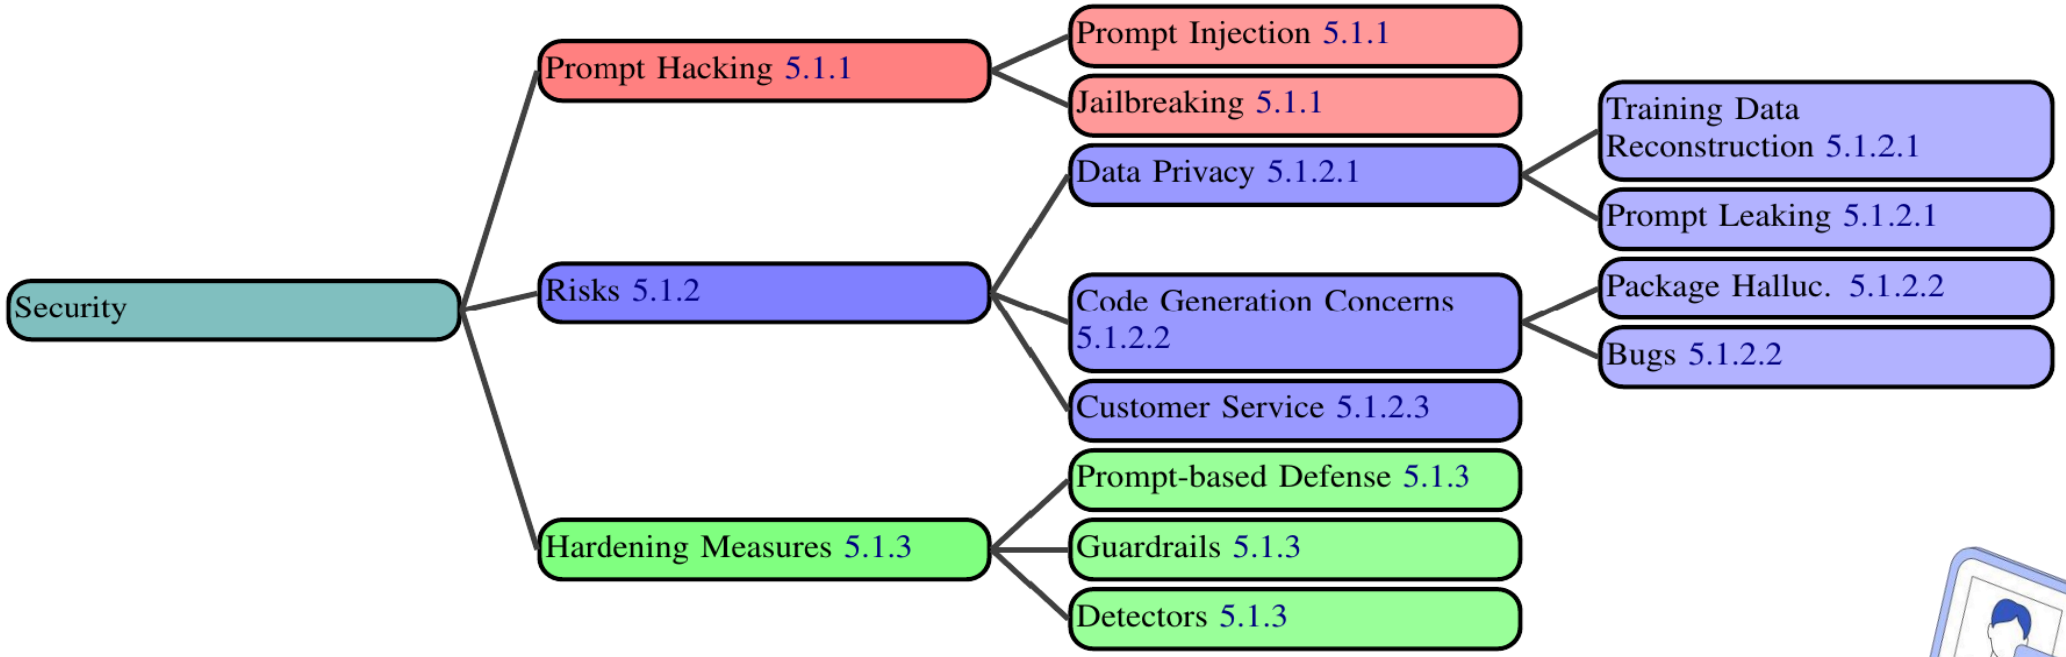
Security
Prompt Hacking 5.1.1
Risks 5.1.2
Hardening Measures 5.1.3
Prompt Injection 5.1.1
Jailbreaking 5.1.1
Data Privacy 5.1.2.1
Code Generation Concerns 5.1.2.2
Customer Service 5.1.2.3
Prompt-based Defense 5.1.3
Guardrails 5.1.3
Detectors 5.1.3
Training Data Reconstruction 5.1.2.1
Prompt Leaking 5.1.2.1
Package Halluc. 5.1.2.2
Bugs 5.1.2.2

Escuela de Gerencia

# Fundamentos Seguridad

- Prompt Hacking
  - Inyección de Indicaciones
    - **Instrucciones maliciosas**
    - Ejemplo: *"Ignorar todas las instrucciones anteriores"*
  - Jailbreaking
    - **Generar contenido inapropiado**
    - **Revelar información privada**
- Riesgos de Seguridad
  - Privacidad de Datos
    - **Obtención de información privada**
  - Generación de Código Malicioso
    - **Código vulnerable**
    - Alucinación de nombres de paquetes
- Medidas de Seguridad
  - Defensas Basadas en Indicaciones
    - **Instrucciones adicionales**
    - Ejemplo: *"No generar contenido malicioso"*
  - Guardrails
    - **Reglas para controlar respuestas**
    - Clasificación de indicaciones

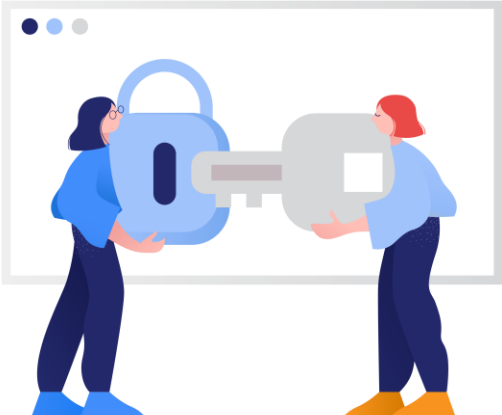

# Alineamiento

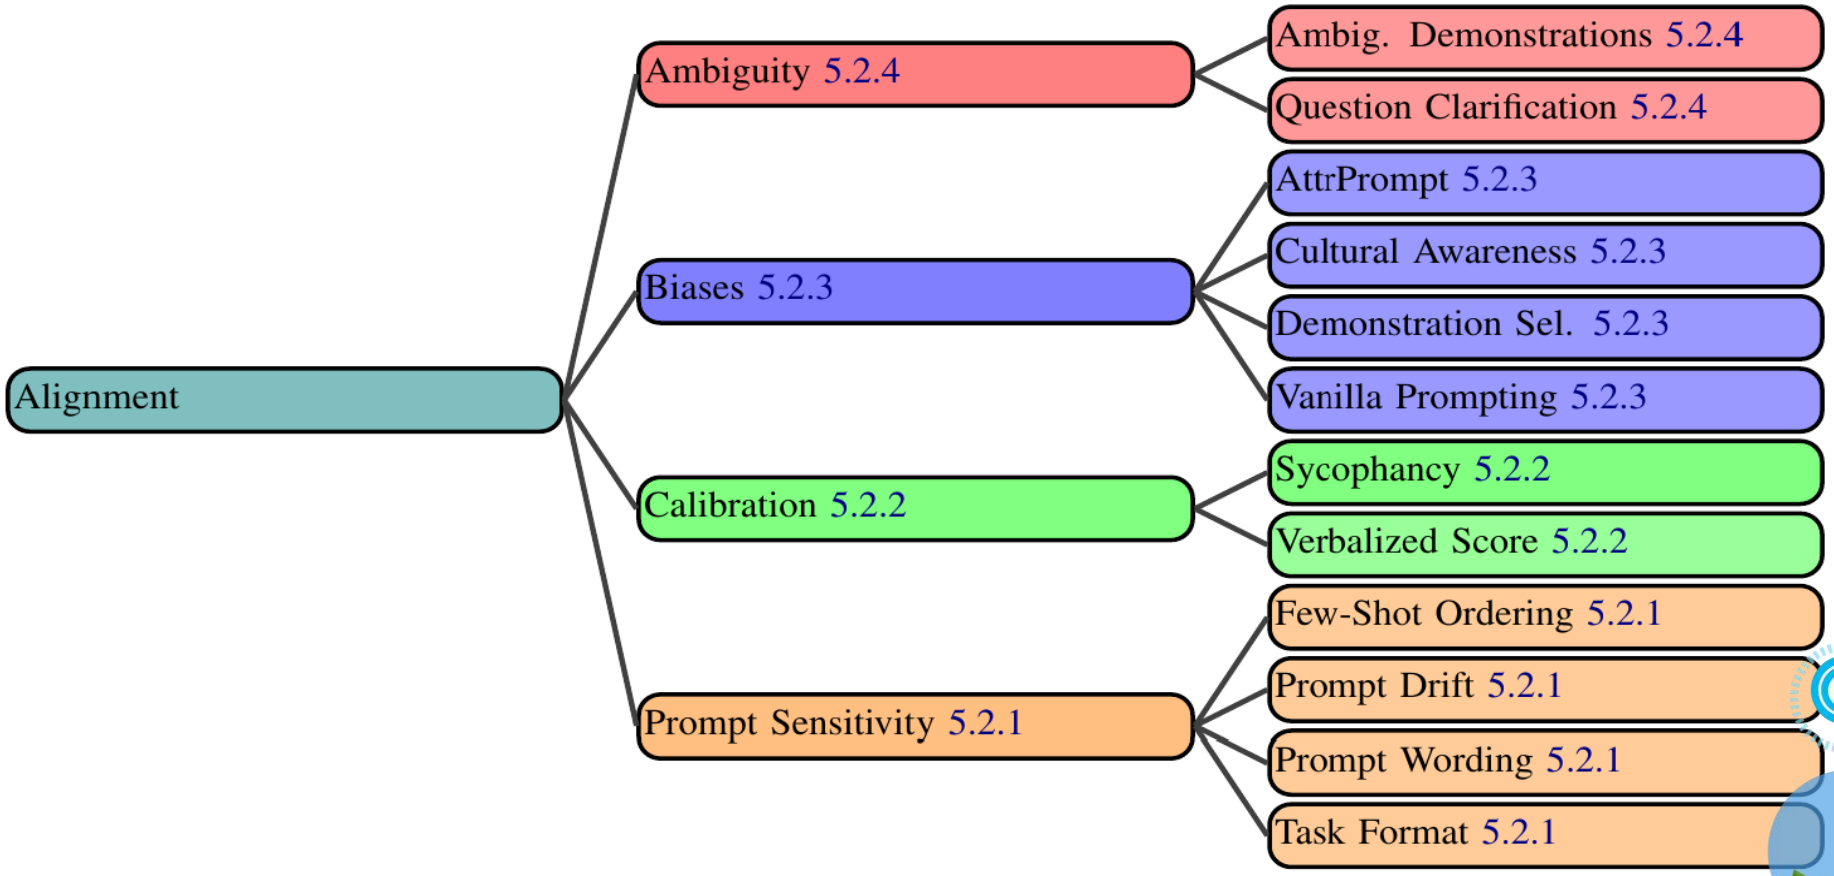

# Fundamentos Alineamiento

- Sensibilidad a la Indicación
  - Redacción de la Indicación
    - *Efecto de cambios mínimos*
  - Formato de la Tarea
    - *Diferentes formas de solicitar tareas*
  - Prompt Drift
    - *Cambio de comportamiento con el tiempo*
- Exceso de Confianza y Calibración
  - *Peligros del exceso de confianza*
- Sesgos, Estereotipos y Cultura
  - Indicaciones "Vanilla"
    - **Instrucciones imparciales**
  - Selección de Demostraciones Equilibradas
    - *Ejemplos diversos*
  - Conciencia Cultural
    - *Información cultural relevante*
- Ambigüedad
  - Demostraciones Ambiguas
    - *Ejemplos con etiquetas ambiguas*
  - Aclaración de Preguntas
    - *Solicitar aclaraciones al usuario*

# Fundamentos Técnicas Avanzadas

- Técnica de Role Playing
  - Definición: Asignar un rol específico al LLM
  - Ventajas
    - Respuestas más especializadas y contextualizadas
    - Mejora la coherencia en conversaciones largas
  - Limitaciones
    - Puede generar sesgos no deseados
    - No garantiza experticia real
  - JailBreak
    - Intento de eludir las restricciones éticas del modelo
    - Riesgos éticos y legales
- Generated Knowledge Prompting y Knowledge Integration
  - Generated Knowledge
    - El modelo genera información adicional antes de responder
    - Mejora la calidad y profundidad de las respuestas
  - Knowledge Integration
    - Combina conocimiento generado con la pregunta original
    - Produce respuestas más informadas y contextualizadas
- Few-Shot CoT y Self-Consistency
  - Few-Shot Chain-of-Thought (CoT)
    - Proporciona ejemplos de razonamiento paso a paso
    - Mejora la capacidad del modelo para problemas complejos
  - Self-Consistency
    - Genera múltiples cadenas de razonamiento
    - Selecciona la respuesta más consistente
    - Aumenta la fiabilidad en tareas de razonamiento

Escuela de Gerencia

# Técnica “Role Playing”

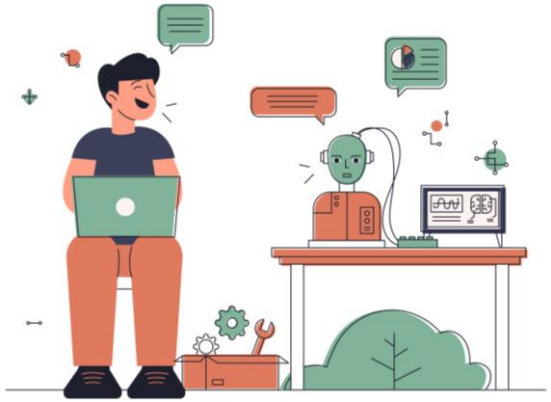

## Prompt:

Eres un equipo multidisciplinario encargado de diseñar una ciudad sostenible para el año 2050. Adoptarás diferentes roles para abordar este desafío desde múltiples perspectivas. Tu objetivo es crear un plan integral que combine innovación, sostenibilidad y habitabilidad.

Roles a asumir:

1. Arquitecto futurista
2. Ingeniero ambiental
3. Planificador urbano
4. Sociólogo
5. Experto en tecnología

Para cada rol, proporciona ideas y soluciones específicas relacionadas con el diseño de la ciudad sostenible. Considera los siguientes aspectos:

- Diseño arquitectónico y uso del espacio
- Sistemas de energía renovable y gestión de recursos
- Planificación de transporte y zonificación
- Impacto social y calidad de vida
- Integración de tecnologías emergentes

Después de aportar desde cada perspectiva, sintetiza las ideas en un plan cohesivo. Aborda cualquier conflicto potencial entre las diferentes visiones y busca soluciones de compromiso.

Finalmente, presenta un plan integral para la ciudad sostenible del 2050 que incorpore las mejores ideas de cada rol y resuelva los desafíos identificados.

Comienza asumiendo el rol del Arquitecto futurista y continúa con los demás roles en orden. Asegúrate de indicar claramente cuándo cambias de un rol a otro.

Escuela de Gerencia

# Fundamentos Técnica “Role Playing”

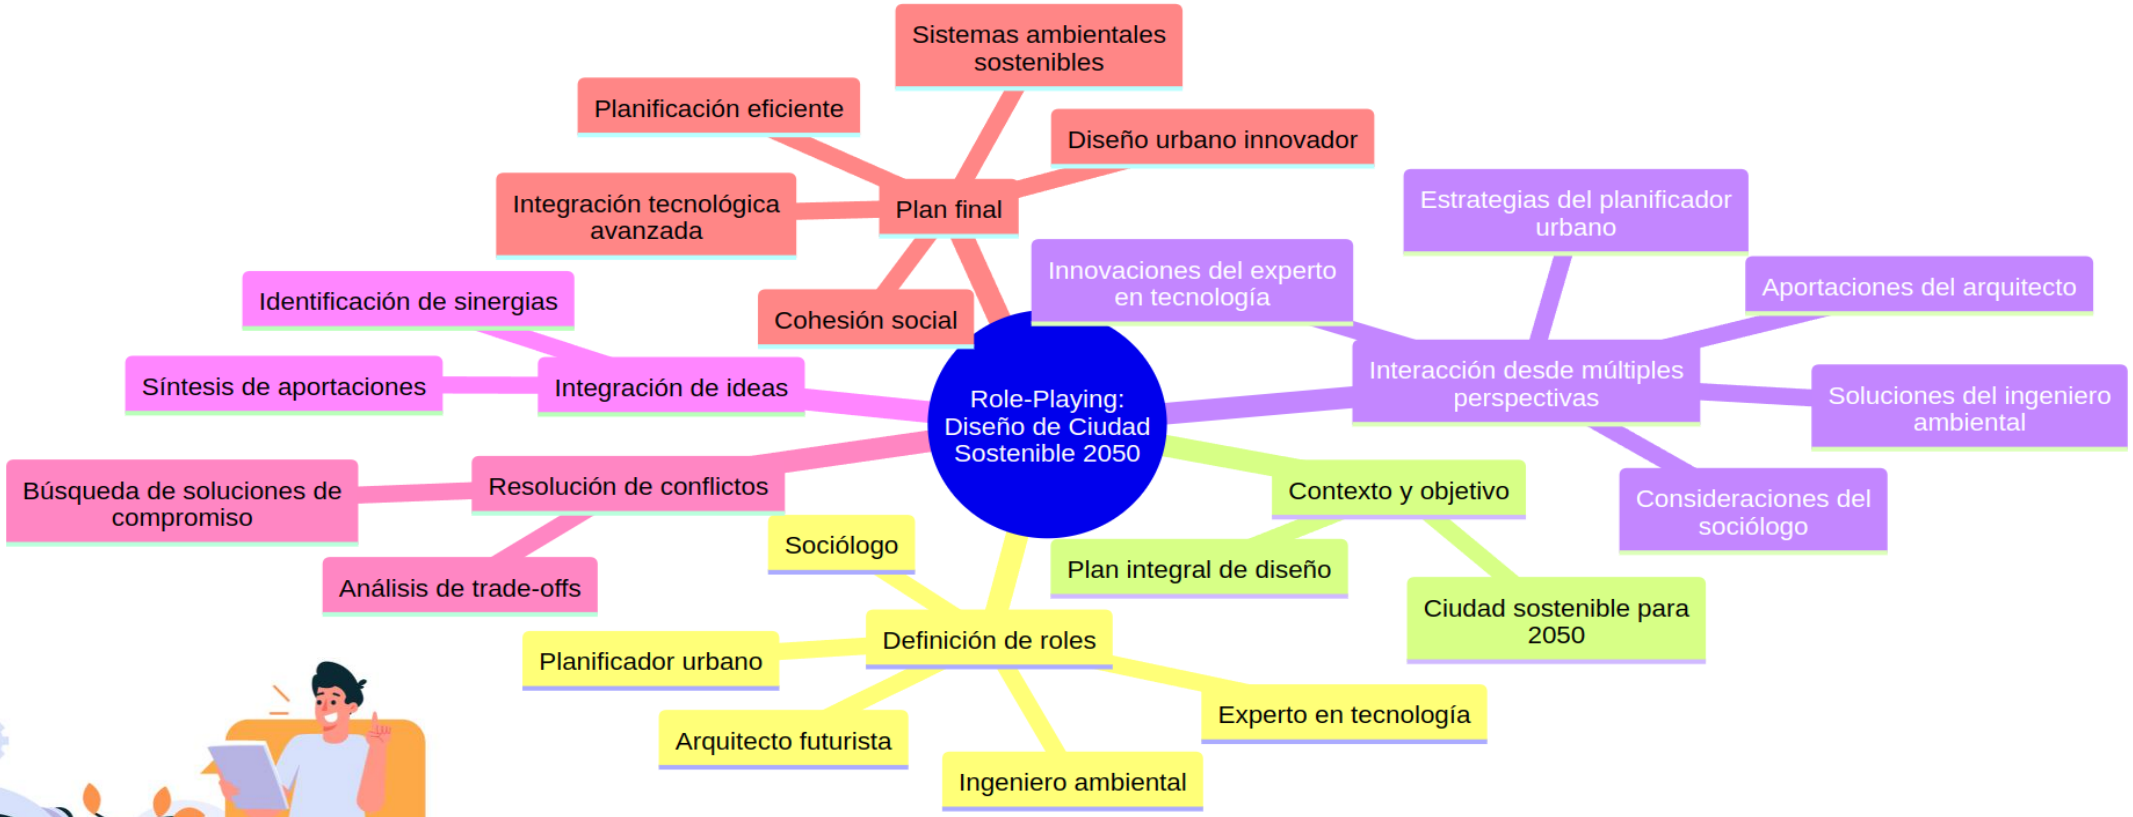

# Prompt:

Eres un detective privado en el Londres victoriano. Describes la escena de un crimen misterioso en una mansión y propone tres posibles sospechosos con sus motivos.

**Explicación:** Este prompt asigna un rol específico y un contexto histórico, fomentando una respuesta creativa y coherente con el personaje.

Asume el papel de un consejero financiero experimentado. Un cliente joven acaba de recibir una herencia inesperada de 500,000 dólares y te pide consejo sobre cómo invertir sabiamente. ¿Qué recomendaciones le darías y por qué?

**Explicación:** Este prompt establece un escenario profesional específico, requiriendo una respuesta que demuestre conocimientos financieros y habilidades de asesoramiento.
Técnica de Role Playing
El role playing puede ser muy efectivo en situaciones que requieren empatía o perspectivas específicas:

# Técnica “Generated Knowledge” y “Knowledge Integration”

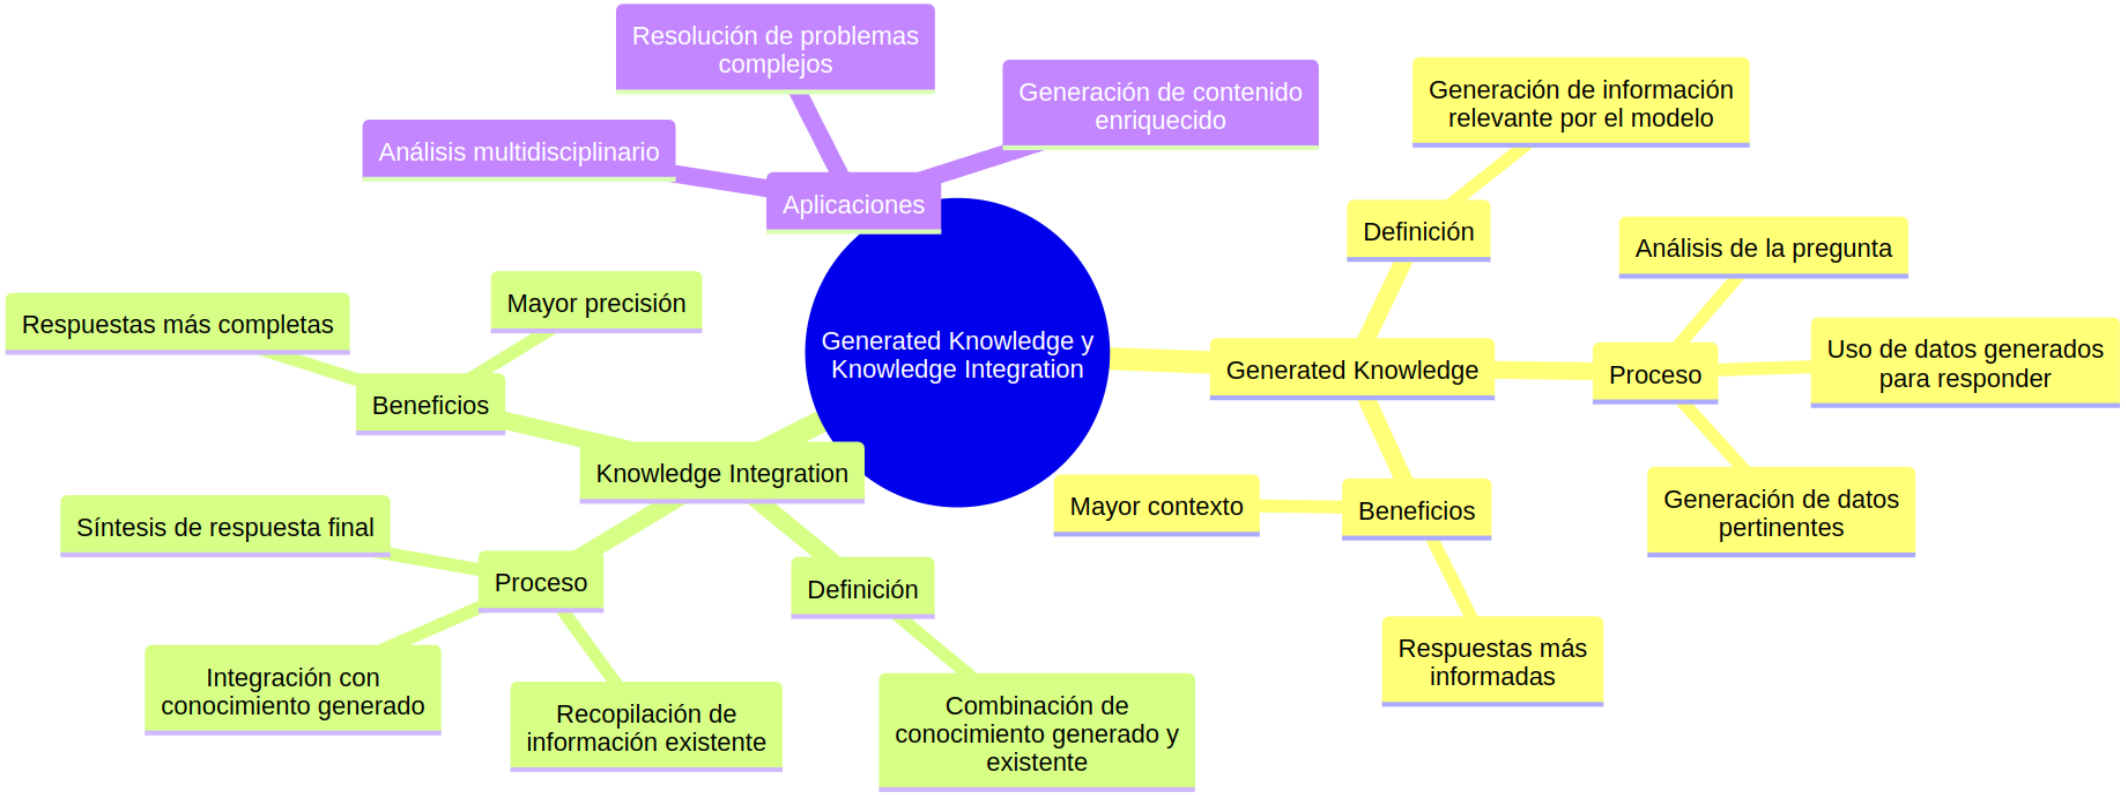

# Generated Knowledge

## Prompt:

Eres un experto en tecnología y seguridad informática. Tu tarea es analizar el impacto potencial de la computación cuántica en la criptografía moderna. Sigue estos pasos:

1. Genera conocimiento sobre los principios básicos de la computación cuántica, incluyendo superposición y entrelazamiento.
2. Describe los algoritmos cuánticos más relevantes para la criptografía, como el algoritmo de Shor y el algoritmo de Grover.
3. Investiga y resume el estado actual de desarrollo de las computadoras cuánticas.
4. Genera conocimiento sobre los métodos de encriptación actuales más comunes, como RSA y ECC, incluyendo sus principios matemáticos subyacentes y vulnerabilidades conocidas.
5. Analiza cómo los avances en computación cuántica podrían afectar a estos sistemas criptográficos.
6. Investiga y describe los nuevos métodos de criptografía post-cuántica que se están desarrollando.
7. Sintetiza toda esta información para proporcionar un análisis completo del impacto potencial de la computación cuántica en la criptografía moderna.

# Fundamentos “Generated Knowledge”

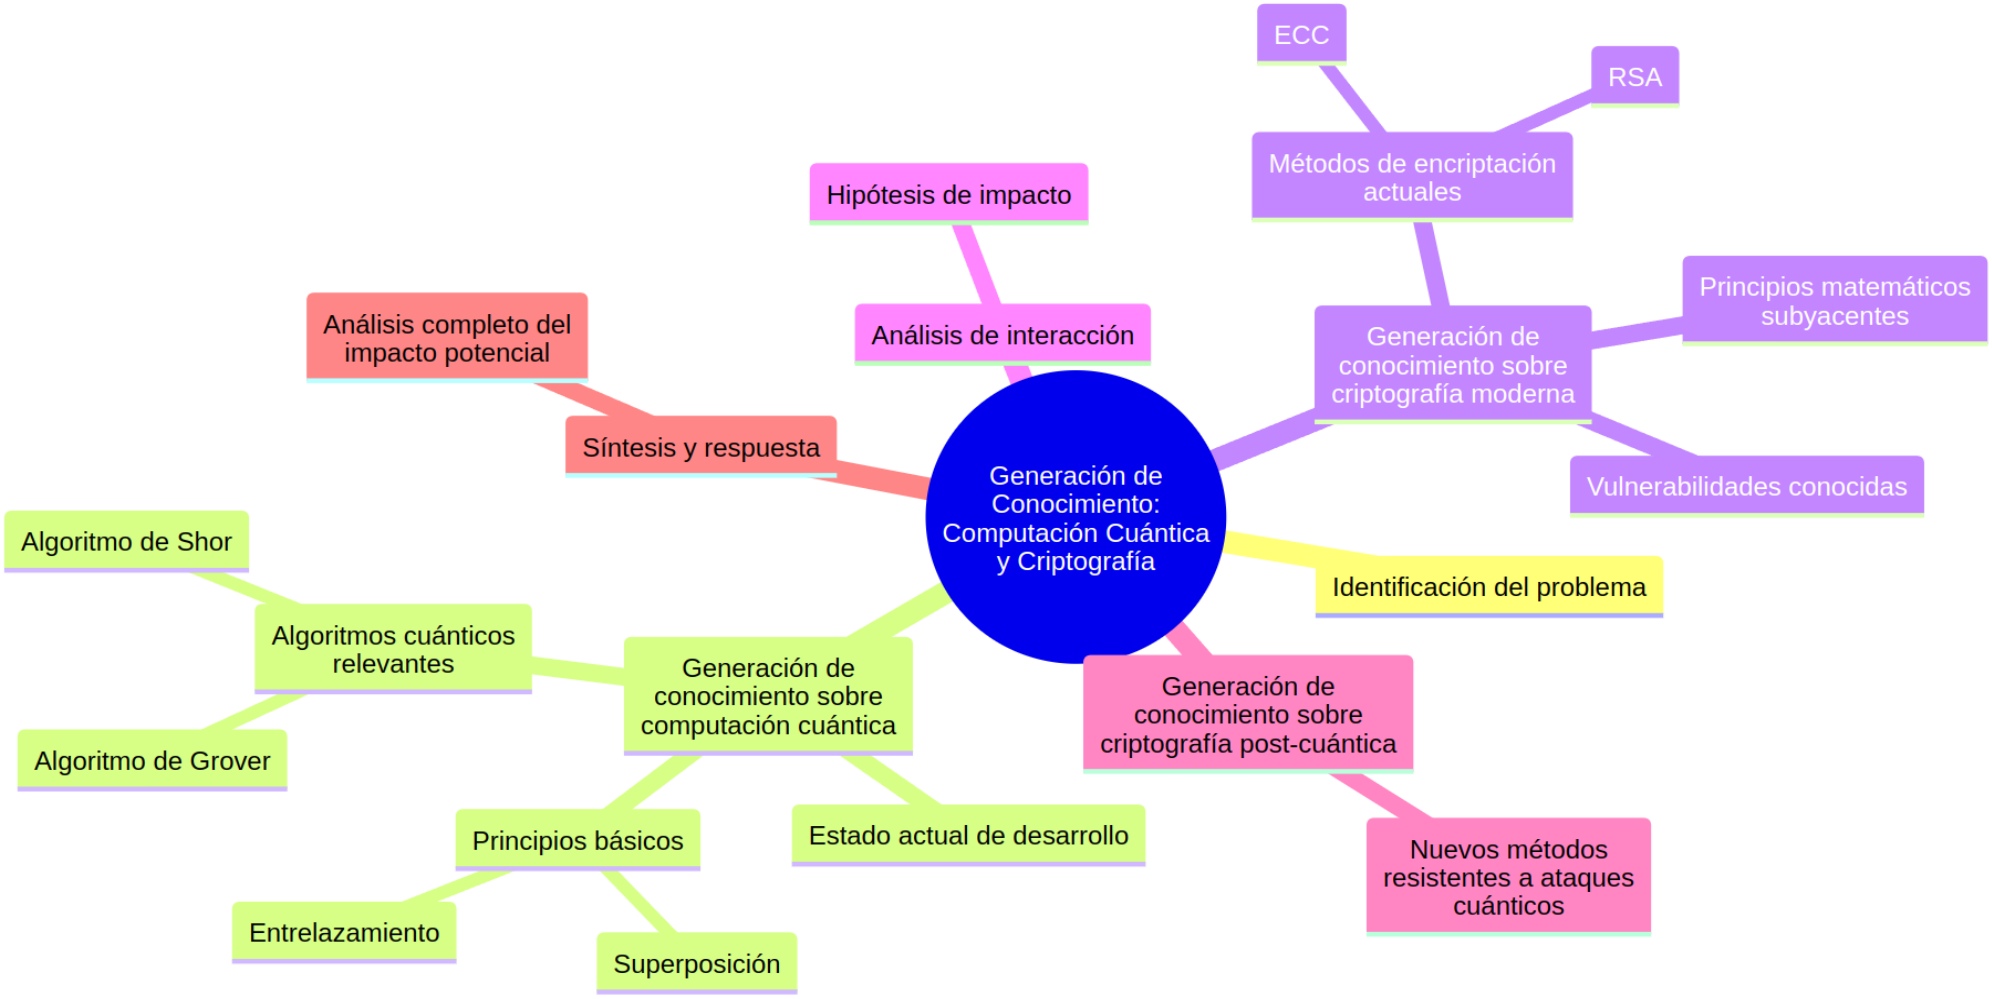

# Knowledge Integration

## Prompt:

Eres un consultor experto en cambio climático y planificación urbana. Tu tarea es desarrollar una estrategia de mitigación del cambio climático para una ciudad costera. Sigue estos pasos:

1. Recopila el siguiente conocimiento existente:
   a) Datos climáticos históricos de la ciudad (temperatura, precipitaciones, eventos extremos)
   b) Proyecciones de aumento del nivel del mar para la región
   c) Descripción de la infraestructura actual de la ciudad (sistemas de drenaje, protección costera, etc.)
2. Genera conocimiento adicional sobre:
   a) Los modelos de cambio climático más recientes y sus implicaciones para las ciudades costeras
   b) Tecnologías emergentes de mitigación climática aplicables a entornos urbanos costeros
   c) Estrategias exitosas implementadas en otras ciudades costeras alrededor del mundo
3. Integra estos conocimientos:
   a) Combina los datos históricos con las proyecciones futuras para crear un panorama claro de los desafíos que enfrentará la ciudad
   b) Analiza cómo las tecnologías emergentes podrían aplicarse a la infraestructura existente de la ciudad
   c) Evalúa qué estrategias exitosas de otras ciudades podrían ser más efectivas en el contexto único de esta ciudad
4. Identifica las brechas de conocimiento que aún existen y que requieren más investigación.
5. Genera múltiples escenarios de mitigación basados en el conocimiento integrado.
6. Evalúa cada escenario en términos de factibilidad, costo y eficacia.
7. Formula una estrategia integral de mitigación del cambio climático para la ciudad, basada en todo el conocimiento integrado y los escenarios evaluados.

# Fundamentos “Knowledge Integration”

# Prompt:

Genera una lista de 5 hechos importantes sobre la Revolución Industrial. Luego, utiliza esa información para explicar cómo la Revolución Industrial cambió la estructura social de las ciudades europeas en el siglo XIX.

**Explicación:** Este prompt primero solicita la generación de conocimiento específico y luego pide que se integre ese conocimiento en una explicación más amplia.

# Prompt:

Enumera las principales características de la pintura impresionista. Basándote en esa información, analiza cómo estas características se manifiestan en el cuadro 'Impresión, sol naciente' de Claude Monet.

**Explicación:** Similar al anterior, este prompt genera conocimiento sobre un tema y luego solicita su aplicación en un análisis específico.

# Técnica “Few-Shot CoT”

# Knowledge Integration

## Prompt:

Eres un experto en diagnóstico de sistemas informáticos complejos. Te proporcionaré algunos ejemplos de diagnósticos paso a paso y luego te presentaré un nuevo problema para que lo analices. Sigue un proceso de pensamiento similar al de los ejemplos.

Ejemplo 1: Problema de red
Síntomas: Conexiones lentas, pérdida intermitente de paquetes
Paso 1: Verificar la conectividad física
Paso 2: Analizar los logs del router
Paso 3: Realizar pruebas de velocidad en diferentes puntos
Paso 4: Identificar patrones de tráfico anormales
Diagnóstico: Congestión en un switch principal debido a un loop de spanning tree
Solución: Reconfigurar el spanning tree y actualizar el firmware del switch

Ejemplo 2: Error de base de datos
Síntomas: Tiempos de respuesta lentos, errores ocasionales de "tabla bloqueada"
Paso 1: Revisar los logs de la base de datos
Paso 2: Analizar las consultas más frecuentes y su rendimiento
Paso 3: Verificar el uso de índices y su eficiencia
Paso 4: Examinar los patrones de bloqueo de tablas
Diagnóstico: Índices mal optimizados y consultas ineficientes causando bloqueos excesivos
Solución: Optimizar índices, reescribir consultas problemáticas y aumentar el timeout de transacciones

Ahora, diagnostica el siguiente problema:

Un sistema de comercio electrónico experimenta caídas aleatorias durante las horas pico de tráfico. Los usuarios reportan errores al finalizar las compras, y el panel de administración muestra picos de uso de CPU y memoria. El sistema utiliza una arquitectura de microservicios con balanceadores de carga, servicio de autenticación, servicio de catálogo, servicio de carrito de compras y servicio de procesamiento de pagos.

Por favor, proporciona un diagnóstico detallado paso a paso y una solución propuesta.

# Fundamentos Técnica “Few-Shot CoT”

# Prompt:

Resuelve los siguientes problemas de lógica, mostrando tu razonamiento paso a paso:

Ejemplo 1:
Pregunta: Si todos los gatos son mamíferos y todos los mamíferos respiran oxígeno, ¿qué podemos concluir sobre los gatos?
Razonamiento:
1. Todos los gatos son mamíferos (dado)
2. Todos los mamíferos respiran oxígeno (dado)
3. Por lo tanto, si los gatos son mamíferos y los mamíferos respiran oxígeno, los gatos deben respirar oxígeno
Conclusión: Los gatos respiran oxígeno.

Ahora, resuelve este problema:
Si todos los músicos son artistas y todos los artistas son creativos, ¿qué podemos concluir sobre los músicos?

**Explicación:** Este prompt proporciona un ejemplo de razonamiento paso a paso antes de presentar un nuevo problema, guiando al modelo en cómo estructurar su pensamiento.

# Técnica “Self-Consistency”

# Prompt:

Eres un analista experto en tecnología y tendencias de mercado. Tu tarea es predecir el impacto de una nueva tecnología emergente en múltiples industrias utilizando la técnica de Self-Consistency. Sigue estos pasos:

1. La tecnología a analizar es la "Computación Neuromórfica" (chips que imitan la estructura y función del cerebro humano). Las industrias a considerar son: Automóvil, Salud, Finanzas y Entretenimiento.
2. Genera cuatro predicciones independientes para cada industria. Cada predicción debe considerar diferentes aspectos y posibles resultados. No te preocupes si hay contradicciones entre las predicciones.
3. Analiza las consistencias e inconsistencias entre tus predicciones para cada industria. Identifica patrones comunes y discrepancias significativas.
4. Reevalúa las predicciones que difieran significativamente de la mayoría. Considera si hay razones válidas para estas diferencias o si deben ajustarse.
5. Sintetiza las predicciones más consistentes para cada industria, combinando los elementos comunes y resolviendo contradicciones menores.
6. Proporciona una predicción final consolidada del impacto de la Computación Neuromórfica en cada una de las industrias mencionadas.

Asegúrate de explicar tu proceso de pensamiento en cada paso y cómo llegaste a tus conclusiones finales. Tu análisis debe ser detallado, considerando factores como la adopción de la tecnología, los cambios en los modelos de negocio, las mejoras en eficiencia o rendimiento, y los posibles desafíos o limitaciones.

# Fundamentos Técnica “Self-Consistency”

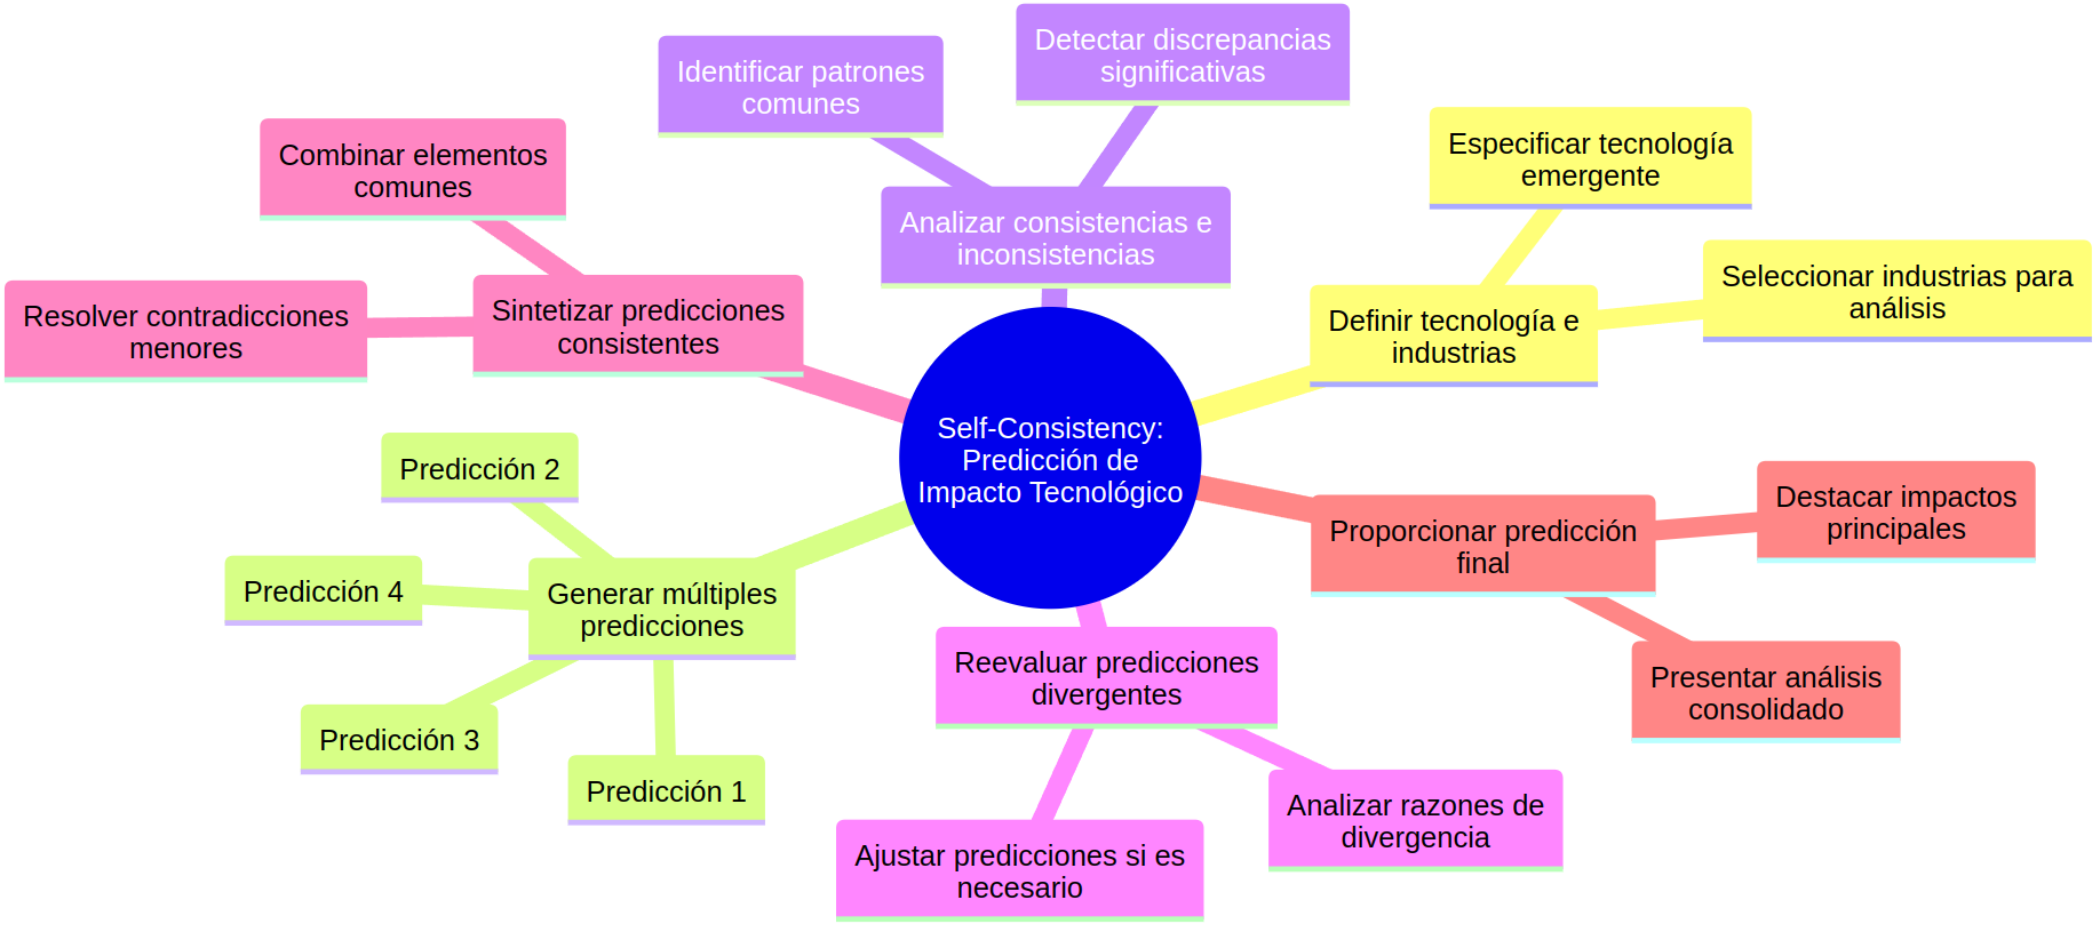

# Prompt:

Genera tres diferentes explicaciones para el siguiente fenómeno: 'Por qué el cielo es azul'. Luego, analiza cada explicación y determina cuál es la más consistente y precisa basándose en principios científicos.

**Explicación:** Este prompt solicita múltiples explicaciones y luego pide al modelo que evalúe y seleccione la más consistente, fomentando un proceso de auto-verificación.

Escuela de Gerencia

# ¡Gracias!

www.egci.es